

系统开发综合实训项目设计—— 基于多技术栈的数据分析与AI知识库构建

实训基本信息

- **实训名称：**多源数据处理与AI知识库构建综合实训
- **实训课时：**72课时
- **实训目标：**掌握数据采集、存储、挖掘、Spark分布式分析、数据可视化的核心技术，能独立完成从原始数据到AI知识库的全流程开发，提升系统开发、问题排查的能力。
- **实训环境：**
 - 软件：Python 3.8+、Hadoop 3.x、Spark 3.x、MySQL 8.0、MongoDB、Redis、request、ECharts、LangChain等
- **实训结果：**最终的结果以Web的形式展现，并且支持数据即时更新。

模块一：数据采集技术

利用爬虫技术按关键字爬取哔哩哔哩视频的标题、视频url、评论、播放量、博主、点赞、投币、收藏、转发等数据。如按大数据技术，爬取数据至少10000条。



模块二：数据清洗技术

利用pandas处理模块一爬取的数据，如播放量把单位统一：“万”字去掉（1.1万->11000）等。

模块三：数据存储技术

将模块二清洗好的数据存储到存储系统 MySQL + MongoDB + Redis + HDFS 中，自己任选2个以上存储系统。

模块四：数据挖掘（聚类、预测、关联）

从模块三的存储系统中读取数据，使用机器学习算法对数据进行聚类，然后根据特征预测某视频是否能成为爆款，使用关联规则算法找出 点赞 → 投币 点赞 → 收藏 投币 → 转发等之间的关联性

关联规则	支持度	置信度
投币 -> 点赞	0.82	1
投币 -> 收藏	0.82	1
点赞, 投币 -> 收藏	0.82	1
投币 -> 收藏, 点赞	0.82	1
收藏, 投币 -> 点赞	0.82	1
收藏, 转发, 投币 -> 点赞	0.81	1
转发, 点赞, 投币 -> 收藏	0.81	1
转发, 投币 -> 收藏	0.81	1
收藏, 转发 -> 点赞	0.84	1
转发, 投币 -> 点赞	0.81	1
转发, 投币 -> 收藏, 点赞	0.81	1
收藏 -> 点赞	0.89	1
转发 -> 点赞	0.84	1
转发, 点赞 -> 收藏	0.84	1

模块五： Spark 分布式分析

从模块三的存储系统中读取数据，使用Spark进行数据分析，至少分析4种数据

模块六：数据可视化

将模块五分析后的数据传到前端，使用Echarts可视化展示，至少展示4个可视化图

模块七： AI 知识库

用爬取的 CSV 内容+ LangChain + 本地离线大模型 构建本地知识库，根据知识库进行问答：

- 哪个 UP 主视频最多？
- 播放量最高的视频是哪个？
- 哪些视频点赞投币最高？

AI 知识库问答

播放量最高的视频

向AI提问

播放量最多的视频是：
标题：整整600集清华大学196小时讲的AI人工智能从入门到精通全套教程全程干货无废话学完变大佬这还学不会我退出IT圈机器学习深度学习opencv
UP主：IT界扛霸子
播放量：205000

AI 知识库问答

点赞数最高的视频



AI思考中，请稍候...

AI 知识库问答

点赞数最高的视频

向AI提问

点赞数最高的视频是《AI与安全守护还是威胁》（UP主：科普中国），该视频获得了133个赞。

其他功能

- 1.用户登录，区分普通用户和管理员，管理员才有权限采集数据
- 2.数据采集支持手动采集和自动采集，每日凌晨自动采集前一天的数据
- 3.每日登录系统，所有数据和功能都是展示前一天的数据
- 4.所有功能支持选择日期，如对不同日期进行数据分析和可视化展示，数据挖掘、关联规则等